

Cálculo dos Pesos das Arestas na GNN Ponderada

1 Ideia geral

Considere um grafo

$$G = (V, E),$$

em que V é o conjunto de nós e E é o conjunto de arestas. No contexto do notebook, cada nó representa uma estação meteorológica, e cada estação possui uma posição espacial. Denotamos a posição do nó i por

$$x_i \in \mathbb{R}^d.$$

No caso usual de coordenadas bidimensionais, temos

$$x_i = \begin{bmatrix} x_{i,1} \\ x_{i,2} \end{bmatrix},$$

onde $x_{i,1}$ e $x_{i,2}$ podem representar latitude e longitude, ou outro sistema de coordenadas usado no grafo.

A proposta é atribuir a cada aresta (i, j) um peso que diminui conforme a distância entre os nós aumenta. O peso bruto da aresta é definido por

$$w_{ij} = e^{-\|x_i - x_j\|_2}.$$

Assim, nós próximos recebem pesos maiores, e nós distantes recebem pesos menores.

2 Distância euclidiana

A norma usada é a norma euclidiana. Para dois nós i e j , a distância entre suas posições é

$$d_{ij} = \|x_i - x_j\|_2.$$

Se

$$x_i = \begin{bmatrix} x_{i,1} \\ x_{i,2} \end{bmatrix} \quad \text{e} \quad x_j = \begin{bmatrix} x_{j,1} \\ x_{j,2} \end{bmatrix},$$

então

$$x_i - x_j = \begin{bmatrix} x_{i,1} - x_{j,1} \\ x_{i,2} - x_{j,2} \end{bmatrix}.$$

Logo,

$$\|x_i - x_j\|_2 = \sqrt{(x_{i,1} - x_{j,1})^2 + (x_{i,2} - x_{j,2})^2}.$$

De forma geral, se $x_i, x_j \in \mathbb{R}^d$, então

$$\|x_i - x_j\|_2 = \sqrt{\sum_{r=1}^d (x_{i,r} - x_{j,r})^2}.$$

3 Peso bruto da aresta

Depois de calcular a distância d_{ij} , o peso bruto da aresta é dado por

$$w_{ij} = e^{-d_{ij}}.$$

Como $d_{ij} \geq 0$, temos

$$0 < e^{-d_{ij}} \leq 1.$$

Além disso:

$$d_{ij} = 0 \implies w_{ij} = e^0 = 1,$$

e, quando d_{ij} cresce,

$$w_{ij} = e^{-d_{ij}}$$

se aproxima de zero.

Portanto, o peso tem a seguinte interpretação:

quanto menor a distância entre os nós, maior o peso da aresta.

4 Matriz de adjacência ponderada

No modelo original, a matriz de adjacência A era binária. Isto é,

$$A_{ij} = \begin{cases} 1, & \text{se existe aresta entre } i \text{ e } j, \\ 0, & \text{caso contrário.} \end{cases}$$

Na versão ponderada, substituímos o valor 1 pelo peso w_{ij} . Definimos a matriz de adjacência ponderada $\tilde{A}$ por

$$\tilde{A}_{ij} = \begin{cases} e^{-\|x_i - x_j\|^2}, & \text{se } (i, j) \in E, \\ 0, & \text{se } (i, j) \notin E. \end{cases}$$

Como o grafo usado no notebook é não direcionado, a matriz é simétrica:

$$\tilde{A}_{ij} = \tilde{A}_{ji}.$$

Também são adicionados self-loops, isto é, cada nó é conectado a si mesmo. No código, o peso do self-loop foi escolhido como

$$\tilde{A}_{ii} = 1.$$

Assim, cada nó preserva parte da sua própria informação durante a agregação.

5 Normalização por linha

Se usarmos diretamente $\tilde{A}$, nós com mais vizinhos ou pesos maiores podem acumular valores maiores na agregação. Para evitar isso, normalizamos cada linha da matriz.

O grau ponderado do nó i é

$$s_i = \sum_{j=1}^N \tilde{A}_{ij}.$$

A matriz normalizada é definida por

$$A_{ij}^{(\text{norm})} = \frac{\tilde{A}_{ij}}{s_i}.$$

Portanto,

$$\sum_{j=1}^N A_{ij}^{(\text{norm})} = \sum_{j=1}^N \frac{\tilde{A}_{ij}}{s_i} = \frac{1}{s_i} \sum_{j=1}^N \tilde{A}_{ij} = \frac{s_i}{s_i} = 1.$$

Isso significa que cada linha da matriz normalizada soma 1. Logo, a operação

$$A^{(\text{norm})} H$$

calcula uma média ponderada das representações dos vizinhos.

6 Agregação no modelo GNN

No modelo implementado, a cada camada oculta temos a operação

$$H \leftarrow A^{(\text{norm})} H.$$

Para o nó i , isso equivale a

$$\bar{h}_i = \sum_{j=1}^N A_{ij}^{(\text{norm})} h_j,$$

onde h_j é a representação do nó j antes da agregação.

Depois da agregação, aplica-se uma camada linear e uma função de ativação ReLU:

$$h_i^{(\ell+1)} = \text{ReLU} \left(W^{(\ell)} \bar{h}_i + b^{(\ell)} \right).$$

Como

$$\bar{h}_i = \sum_{j=1}^N \frac{\tilde{A}_{ij}}{s_i} h_j,$$

temos

$$h_i^{(\ell+1)} = \text{ReLU} \left(W^{(\ell)} \sum_{j=1}^N \frac{\tilde{A}_{ij}}{s_i} h_j + b^{(\ell)} \right).$$

Substituindo o peso bruto,

$$\tilde{A}_{ij} = e^{-\|x_i - x_j\|_2},$$

obtemos, para $i \neq j$ e $(i, j) \in E$,

$$h_i^{(\ell+1)} = \text{ReLU} \left(W^{(\ell)} \sum_{j=1}^N \frac{e^{-\|x_i - x_j\|_2}}{\sum_{k=1}^N \tilde{A}_{ik}} h_j + b^{(\ell)} \right).$$

O self-loop entra na soma com peso bruto

$$\tilde{A}_{ii} = 1.$$

7 Exemplo numérico simples

Considere três nós com posições

$$x_0 = (0, 0), \quad x_1 = (1, 0), \quad x_2 = (0, 2).$$

Suponha que o grafo tenha as arestas

$$E = \{(0, 1), (0, 2)\},$$

e que o grafo seja não direcionado. Portanto, também existem as conexões

$$(1, 0) \quad \text{e} \quad (2, 0).$$

7.1 Distâncias

A distância entre os nós 0 e 1 é

$$d_{01} = \|x_0 - x_1\|_2 = \sqrt{(0 - 1)^2 + (0 - 0)^2} = \sqrt{1} = 1.$$

A distância entre os nós 0 e 2 é

$$d_{02} = \|x_0 - x_2\|_2 = \sqrt{(0 - 0)^2 + (0 - 2)^2} = \sqrt{4} = 2.$$

7.2 Pesos brutos

Os pesos brutos são

$$w_{01} = e^{-d_{01}} = e^{-1} \approx 0.3679,$$

e

$$w_{02} = e^{-d_{02}} = e^{-2} \approx 0.1353.$$

Como o grafo é não direcionado,

$$w_{10} = w_{01} \quad \text{e} \quad w_{20} = w_{02}.$$

Com self-loops de peso 1, a matriz ponderada fica

$$\tilde{A} = \begin{bmatrix} 1 & 0.3679 & 0.1353 \\ 0.3679 & 1 & 0 \\ 0.1353 & 0 & 1 \end{bmatrix}.$$

7.3 Graus ponderados

O grau ponderado do nó 0 é

$$s_0 = 1 + 0.3679 + 0.1353 = 1.5032.$$

O grau ponderado do nó 1 é

$$s_1 = 0.3679 + 1 = 1.3679.$$

O grau ponderado do nó 2 é

$$s_2 = 0.1353 + 1 = 1.1353.$$

7.4 Matriz normalizada

Cada linha é dividida pelo seu respectivo grau ponderado:

$$A_{ij}^{(\text{norm})} = \frac{\tilde{A}_{ij}}{s_i}.$$

Assim,

$$A^{(\text{norm})} \approx \begin{bmatrix} 0.6652 & 0.2447 & 0.0900 \\ 0.2689 & 0.7311 & 0 \\ 0.1192 & 0 & 0.8808 \end{bmatrix}.$$

Note que cada linha soma aproximadamente 1:

$$0.6652 + 0.2447 + 0.0900 \approx 1,$$

$$0.2689 + 0.7311 \approx 1,$$

$$0.1192 + 0.8808 \approx 1.$$

7.5 Agregação de features

Suponha que cada nó tenha uma única feature:

$$H = \begin{bmatrix} 10 \\ 20 \\ 30 \end{bmatrix}.$$

A agregação ponderada é

$$\bar{H} = A^{(\text{norm})} H.$$

Para o nó 0,

$$\bar{h}_0 = 0.6652 \cdot 10 + 0.2447 \cdot 20 + 0.0900 \cdot 30.$$

Logo,

$$\bar{h}_0 \approx 6.652 + 4.894 + 2.700 = 14.246.$$

Para o nó 1,

$$\bar{h}_1 = 0.2689 \cdot 10 + 0.7311 \cdot 20 \approx 17.311.$$

Para o nó 2,

$$\bar{h}_2 = 0.1192 \cdot 10 + 0.8808 \cdot 30 \approx 27.616.$$

Portanto,

$$\bar{H} \approx \begin{bmatrix} 14.246 \\ 17.311 \\ 27.616 \end{bmatrix}.$$

Esse vetor agregado é o que entra na camada linear da GNN.

8 Relação com o código

No notebook, a matriz com pesos brutos corresponde a

$$\tilde{A} = \text{A_weighted}.$$

A matriz normalizada corresponde a

$$A^{(\text{norm})} = \text{A_norm_weighted}.$$

O modelo usa a matriz normalizada no método `forward`:

$$H \leftarrow A^{(\text{norm})} H.$$

Em código, a parte essencial é:

```
coords_tensor = torch.tensor(coords, dtype=torch.float32)
dist_matrix = torch.cdist(coords_tensor, coords_tensor, p=2)

edge_mask = torch.tensor(A, dtype=torch.float32) > 0
edge_mask.fill_diagonal_(False)

edge_weight_matrix = torch.exp(-dist_matrix)

edge_weights = {
    (int(i), int(j)): float(edge_weight_matrix[i, j])
    for i, j in edge_mask.nonzero(as_tuple=False)
}
```

Depois disso, a função de construção da matriz ponderada transforma esses pesos em $\tilde{A}$, adiciona self-loops e normaliza as linhas para obter $A^{(\text{norm})}$.

9 Observação sobre escala

Se as posições x_i e x_j forem latitude e longitude, a distância euclidiana será calculada em graus, não em quilômetros. Isso segue exatamente a fórmula proposta,

$$w_{ij} = e^{-\|x_i - x_j\|_2},$$

mas a interpretação física da distância depende da escala das coordenadas.

Se a distância estiver em quilômetros, o peso

$$e^{-d_{ij}}$$

pode ficar muito pequeno rapidamente. Nesses casos, uma alternativa comum é usar um parâmetro de escala $\sigma > 0$:

$$w_{ij} = e^{-d_{ij}/\sigma}$$

ou

$$w_{ij} = e^{-d_{ij}^2/(2\sigma^2)}.$$

No entanto, no modelo descrito aqui foi usada a forma solicitada:

$$w_{ij} = e^{-\|x_i - x_j\|_2}.$$