

Graph Convolutional Networks: modelo GCN e diferenças em relação a uma GNN vanilla

1 Contexto

O Capítulo 4 de *Graph Neural Networks: Foundations, Frontiers, and Applications* apresenta redes neurais em grafos para classificação de nós. O problema é: dado um grafo

$$G = (V, E),$$

com matriz de adjacência $A \in \mathbb{R}^{N \times N}$ e matriz de atributos dos nós $X \in \mathbb{R}^{N \times C}$, aprender representações

$$H \in \mathbb{R}^{N \times F}$$

que combinem atributos dos nós e estrutura do grafo. Essas representações são então usadas para prever o rótulo de cada nó, por exemplo por uma camada Softmax.

Neste texto, uso “GNN vanilla” para designar a forma genérica de uma rede neural em grafos por passagem de mensagens, como descrita no capítulo: cada nó atualiza sua representação agregando informações dos vizinhos e combinando essa agregação com sua própria representação atual.

2 A GNN vanilla

A ideia central de uma GNN vanilla é atualizar iterativamente a representação de cada nó. Inicialmente,

$$H^0 = X.$$

Em cada camada $k = 1, \dots, K$, para cada nó v , calcula-se

$$\begin{aligned} a_v^k &= \text{AGGREGATE}^k \left(\{H_u^{k-1} : u \in \mathcal{N}(v)\} \right), \\ H_v^k &= \text{COMBINE}^k \left(H_v^{k-1}, a_v^k \right). \end{aligned}$$

Aqui, $\mathcal{N}(v)$ é o conjunto de vizinhos do nó v . A função AGGREGATE resume as informações vindas dos vizinhos, enquanto COMBINE mistura essa informação agregada com o estado atual do próprio nó.

Depois de K camadas, H^K é usado como representação final. Para classificação de nós, pode-se usar

$$\hat{y}_v = \text{Softmax}(W H_v^K),$$

e treinar o modelo minimizando uma perda supervisionada, como entropia cruzada, sobre os nós rotulados.

Essa formulação é bastante geral: ela diz *o que* uma GNN faz, mas não fixa exatamente *como* os vizinhos são ponderados, como a agregação é normalizada, nem qual forma paramétrica é usada na combinação.

3 O modelo GCN

A Graph Convolutional Network, ou GCN, é uma instanciação específica e muito influente dessa ideia geral. Sua regra de propagação em uma camada é

$$H^{k+1} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^k W^k \right).$$

Nessa expressão:

- $\tilde{A} = A + I$ é a matriz de adjacência com auto-conexões;
- I é a matriz identidade, usada para que cada nó também preserve informação de si mesmo;
- $\tilde{D}$ é a matriz diagonal de graus de $\tilde{A}$, com $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$;
- W^k é a matriz de pesos treinável da camada k ;
- σ é uma função de ativação, frequentemente ReLU.

A parte

$$\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$

é a adjacência normalizada simetricamente. Ela controla quanto de informação cada nó recebe de seus vizinhos e evita que nós de grau alto dominem a propagação.

3.1 Interpretação por nó

Para um nó i , a atualização do GCN pode ser vista como uma média ponderada das representações dos vizinhos e do próprio nó:

$$H_i^k = \sigma \left(\sum_{j \in \mathcal{N}(i)} \frac{A_{ij}}{\sqrt{\tilde{D}_{ii} \tilde{D}_{jj}}} H_j^{k-1} W^k + \frac{1}{\tilde{D}_{ii}} H_i^{k-1} W^k \right).$$

Assim, no GCN:

- a agregação é uma média ponderada e normalizada dos vizinhos;
- a combinação inclui explicitamente o próprio nó por meio da auto-conexão;
- a transformação W^k é compartilhada entre todos os nós da camada;
- a atualização inteira pode ser escrita em forma matricial, o que torna a implementação eficiente.

4 Intuição espectral

O capítulo também relaciona o GCN a convoluções espectrais em grafos. Em grafos, não existe uma grade regular como em imagens, então a noção de convolução precisa ser adaptada. Uma abordagem é definir filtros no domínio espectral do Laplaciano do grafo. Para um sinal x nos nós, uma convolução espectral pode ser escrita como

$$g_\theta \star x = U g_\theta U^\top x,$$

onde U contém os autovetores do Laplaciano normalizado do grafo.

Calcular essa operação diretamente é caro. O GCN surge como uma simplificação eficiente: usa uma aproximação de primeira ordem do filtro espectral, adiciona auto-conexões e aplica uma renormalização para estabilizar o treinamento. O resultado prático é justamente a regra

$$H^{k+1} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^k W^k \right).$$

Portanto, o GCN pode ser entendido tanto como uma rede de passagem de mensagens quanto como uma aproximação eficiente de convolução espectral em grafos.

Aspecto	GNN vanilla	GCN
Definição	Estrutura geral baseada em AGGREGATE e COMBINE.	Arquitetura específica com regra matricial fixa de propagação.
Agregação dos vizinhos	Pode ser soma, média, máximo, atenção ou outra função.	Usa média ponderada pela adjacência normalizada simetricamente.
Peso dos vizinhos	Não é determinado pela formulação geral.	É determinado por $\frac{A_{ij}}{\sqrt{D_{ii}D_{jj}}}$.
Auto-informação do nó	Depende da escolha da função COMBINE.	É incorporada sistematicamente por $\tilde{A} = A + I$.
Normalização	Opcional e dependente da arquitetura.	Parte essencial do modelo, usada para controlar escala e estabilidade.
Fundamentação	Passagem de mensagens genérica.	Passagem de mensagens com motivação espectral via aproximação de filtros no Laplaciano.
Parâmetros	Dependem da forma escolhida para agregação e combinação.	Principalmente as matrizes W^k , compartilhadas por todos os nós em cada camada.
Eficiência	Varia conforme a implementação.	Muito eficiente em forma matricial esparsa, com custo proporcional ao número de arestas em implementações adequadas.

5 Diferenças entre GCN e GNN vanilla

6 Por que o GCN funciona bem

O GCN funciona bem porque combina três escolhas simples:

1. **Suavização local:** nós conectados tendem a compartilhar informação, o que ajuda quando nós próximos possuem rótulos ou propriedades semelhantes.
2. **Normalização por grau:** a contribuição de cada vizinho é ajustada pela conectividade dos nós, reduzindo distorções causadas por graus muito diferentes.
3. **Transformação neural:** após misturar informações estruturais, a matriz W^k aprende combinações úteis das características para a tarefa.

Em uma rede com duas camadas, por exemplo, cada nó recebe informação de seus vizinhos de 1 salto na primeira camada e de vizinhos de até 2 saltos na segunda. Isso permite que a representação final codifique uma vizinhança local maior sem abandonar a estrutura do grafo.

7 Limitação: over-smoothing

O capítulo destaca um problema comum em GNNs profundas: o *over-smoothing*. Como cada camada mistura representações entre vizinhos, empilhar muitas camadas pode fazer com que as representações dos nós fiquem cada vez mais parecidas. No limite, nós diferentes podem perder distinções importantes.

No GCN, isso é especialmente intuitivo: a aplicação repetida da matriz normalizada do grafo age como uma suavização laplaciana. Essa suavização pode ser benéfica em poucas camadas, mas excessiva em redes profundas. Por isso, GCNs clássicas costumam usar poucas camadas em tarefas de classificação de nós.

8 Resumo

Uma GNN vanilla é um esquema geral: cada nó agrega mensagens dos vizinhos e combina essas mensagens com sua própria representação. O GCN é uma versão concreta desse esquema. Ele escolhe uma agregação normalizada pela estrutura do grafo, adiciona auto-conexões, usa pesos compartilhados por camada e possui uma interpretação como aproximação eficiente de convolução espectral.

Em termos simples: toda GCN é uma GNN, mas nem toda GNN é uma GCN. A GCN é uma GNN com uma regra de propagação específica, simples, estável e eficiente, especialmente útil para classificação de nós em grafos com atributos.

References

- [1] Lingfei Wu, Peng Cui, Jian Pei e Liang Zhao, eds. *Graph Neural Networks: Foundations, Frontiers, and Applications*. Springer, 2022.
- [2] Thomas N. Kipf e Max Welling. *Semi-Supervised Classification with Graph Convolutional Networks*. ICLR, 2017.
- [3] Keyulu Xu, Weihua Hu, Jure Leskovec e Stefanie Jegelka. *How Powerful are Graph Neural Networks?* ICLR, 2019.