

Notação do framework de GNN com pesos brutos baseados na distância

1 Objetivo

Este texto apresenta uma notação unificada para uma rede neural em grafos (Graph Neural Network, GNN) cuja agregação utiliza pesos de aresta definidos a partir da distância entre os nós. Diferentemente da versão com normalização por linha, os pesos são usados diretamente, sem divisão pelo grau ponderado. A notação identifica explicitamente:

- o nó central, denotado por v_i ;
- a camada da GNN, denotada por k ;
- a agregação calculada para o nó v_i , denotada por $A_{v_i}^{(k)}$;
- a representação do nó v_i após a combinação, denotada por $H_{v_i}^{(k)}$;
- o vetor inicial de features, denotado por $H_{v_i}^{(0)} = X_{v_i}$;
- a saída obtida após a última camada, denotada por $\hat{y}_{v_i}$.

2 Grafo, vizinhança e dados dos nós

Seja $G = (V, E)$ um grafo, em que V é o conjunto de nós e E é o conjunto de arestas. Para um nó $v_i \in V$, sua vizinhança é

$$\mathcal{N}(v_i) = \{v_j \in V : (v_i, v_j) \in E\}. \quad (1)$$

Como o modelo inclui uma autoaresta (self-loop) em cada nó, define-se a vizinhança estendida

$$\mathcal{N}^+(v_i) = \mathcal{N}(v_i) \cup \{v_i\}. \quad (2)$$

Cada nó possui duas informações distintas:

- X_{v_i} : vetor de features fornecido como entrada da GNN;
- $\mathbf{x}_{v_i} \in \mathbb{R}^d$: vetor de posição empregado no cálculo das distâncias e dos pesos das arestas.

Assim, X_{v_i} descreve o nó para a tarefa de aprendizado, enquanto $\mathbf{x}_{v_i}$ determina a intensidade das mensagens trocadas no grafo.

3 Distância e peso bruto das arestas

Para dois nós v_i e v_j , a distância euclidiana entre suas posições è

$$d_{ij} = \|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2 = \sqrt{\sum_{q=1}^d (x_{v_i,q} - x_{v_j,q})^2}. \quad (3)$$

O peso bruto entre os nós è definido por

$$\tilde{a}_{ij} = \begin{cases} \exp(-d_{ij}), & v_j \in \mathcal{N}(v_i), \\ 1, & v_j = v_i, \\ 0, & \text{caso contrário.} \end{cases} \quad (4)$$

Para uma aresta comum, $0 < \tilde{a}_{ij} \leq 1$, e o peso diminui quando a distância aumenta. Para a autoaresta, escolhe-se $\tilde{a}_{ii} = 1$, preservando a informação do próprio nó.

4 Agregação sem normalização por linha

Nesta versão, não se calcula o grau ponderado s_{v_i} e não se define o peso normalizado $\tilde{a}_{ij}/s_{v_i}$. O coeficiente empregado na mensagem de v_j para v_i è diretamente $\tilde{a}_{ij}$.

Consequentemente, a soma dos coeficientes de uma agregação não precisa ser igual a 1:

$$\sum_{v_j \in \mathcal{N}^+(v_i)} \tilde{a}_{ij} \neq 1 \quad \text{em geral.} \quad (5)$$

Isso significa que nós com mais vizinhos, ou com vizinhos associados a pesos maiores, podem produzir vetores agregados com magnitude maior. Essa propriedade è mantida intencionalmente neste modelo.

5 Representações nas camadas da GNN

5.1 Inicialização

A representação inicial do nó v_i è seu vetor de features:

$$H_{v_i}^{(0)} = X_{v_i}. \quad (6)$$

Em geral, $H_{v_i}^{(k-1)}$ representa a informação disponível antes da camada k , enquanto $H_{v_i}^{(k)}$ representa a informação produzida por essa camada.

5.2 Agregação

Para $k = 1, 2, \dots, K$, define-se formalmente

$$A_{v_i}^{(k)} = \text{AGG}^{(k)} \left(\left\{ H_{v_j}^{(k-1)} : v_j \in \mathcal{N}^+(v_i) \right\} \right). \quad (7)$$

No modelo com pesos brutos, a função de agregação è a soma ponderada

$$A_{v_i}^{(k)} = \sum_{v_j \in \mathcal{N}^+(v_i)} \tilde{a}_{ij} H_{v_j}^{(k-1)}. \quad (8)$$

Separando a autoaresta das arestas comuns, obtém-se

$$A_{v_i}^{(k)} = H_{v_i}^{(k-1)} + \sum_{v_j \in \mathcal{N}(v_i)} \exp\left(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2\right) H_{v_j}^{(k-1)}. \quad (9)$$

A contribuição de um vizinho próximo continua sendo maior que a de um vizinho distante. No entanto, o resultado não è dividido pela soma dos pesos.

5.3 Combinação

Depois da agregação, a representação do nó è atualizada por

$$H_{v_i}^{(k)} = \text{COMB}^{(k)} \left\{ H_{v_i}^{(k-1)}, A_{v_i}^{(k)} \right\}. \quad (10)$$

Na implementação considerada, a combinação corresponde a uma transformação linear seguida da ativação ReLU:

$$H_{v_i}^{(k)} = \text{ReLU}\left(W^{(k)} A_{v_i}^{(k)} + b^{(k)}\right), \quad (11)$$

em que $W^{(k)}$ e $b^{(k)}$ são, respectivamente, a matriz de pesos e o vetor de viés aprendidos na camada k . A representação anterior $H_{v_i}^{(k-1)}$ já está contida em $A_{v_i}^{(k)}$ por meio da autoaresta.

Substituindo a agregação, a atualização completa da camada k è

$$H_{v_i}^{(k)} = \text{ReLU}\left[W^{(k)} \left(\sum_{v_j \in \mathcal{N}^+(v_i)} \tilde{a}_{ij} H_{v_j}^{(k-1)} \right) + b^{(k)}\right]. \quad (12)$$

6 Saída da rede

Após K camadas, $H_{v_i}^{(K)}$ è a representação final do nó. Se o modelo possuir uma camada de leitura linear, a saída será

$$\hat{y}_{v_i} = W^{(\text{out})} H_{v_i}^{(K)} + b^{(\text{out})}. \quad (13)$$

Se a última representação já possuir a dimensão da variável de interesse, pode-se adotar diretamente

$$\hat{y}_{v_i} = H_{v_i}^{(K)}. \quad (14)$$

7 Correspondência entre as notações

A correspondência entre a notação baseada nos índices i e ℓ e a notação baseada em v_i e k é apresentada na Tabela 1.

Tabela 1: Correspondência entre as notações dos dois frameworks.

Notação anterior	Notação unificada	Interpretação
$h_i^{(\ell)}$	$H_{v_i}^{(k-1)}$	representação antes da camada k
$\bar{h}_i$	$A_{v_i}^{(k)}$	agregação recebida pelo nó v_i
$h_i^{(\ell+1)}$	$H_{v_i}^{(k)}$	representação depois da camada k
$W^{(\ell)}$	$W^{(k)}$	matriz de pesos da camada k
$b^{(\ell)}$	$b^{(k)}$	vetor de viés da camada k
$\tilde{A}_{ij}$	$\tilde{a}_{ij}$	peso bruto da aresta (v_i, v_j)

O grau ponderado s_i não aparece nessa correspondência porque ele não é necessário quando os pesos brutos são empregados diretamente.

8 Framework final resumido

Para cada nó v_i , inicializa-se

$$H_{v_i}^{(0)} = X_{v_i}. \quad (15)$$

Em seguida, para cada camada $k = 1, 2, \dots, K$, calculam-se

$$A_{v_i}^{(k)} = \sum_{v_j \in \mathcal{N}^+(v_i)} \tilde{a}_{ij} H_{v_j}^{(k-1)}, \quad (16)$$

$$H_{v_i}^{(k)} = \text{ReLU}\left(W^{(k)} A_{v_i}^{(k)} + b^{(k)}\right), \quad (17)$$

com

$$\tilde{a}_{ij} = \begin{cases} \exp\left(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2\right), & v_j \in \mathcal{N}(v_i), \\ 1, & v_j = v_i, \\ 0, & \text{caso contrário.} \end{cases} \quad (18)$$

Finalmente, a saída do nó v_i é calculada a partir de sua representação na última camada, $H_{v_i}^{(K)}$.

9 Exemplo numérico

Este exemplo utiliza quatro nós, duas features por nó, duas camadas de GNN e uma camada linear de saída. A estrutura e os parâmetros são iguais aos do exemplo com normalização, permitindo observar exclusivamente o efeito de usar os pesos brutos.

9.1 Grafo, features e posições

Considere

$$V = \{v_1, v_2, v_3, v_4\}, \quad E = \{(v_1, v_2), (v_2, v_3), (v_2, v_4)\}. \quad (19)$$

As features de entrada e os rótulos são

$$X_{v_1} = \begin{bmatrix} 30 \\ 80 \end{bmatrix}, \quad X_{v_2} = \begin{bmatrix} 35 \\ 85 \end{bmatrix}, \quad X_{v_3} = \begin{bmatrix} 26 \\ 77 \end{bmatrix}, \quad X_{v_4} = \begin{bmatrix} 25 \\ 80 \end{bmatrix}, \quad (20)$$

$$y_{v_1} = 20, \quad y_{v_2} = 20, \quad y_{v_3} = 22, \quad y_{v_4} = 18. \quad (21)$$

As posições usadas para calcular as distâncias são

$$\mathbf{x}_{v_1} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_2} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_3} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_4} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}. \quad (22)$$

9.2 Distâncias e matriz de pesos brutos

As distâncias e os pesos das três arestas são

$$d_{12} = 1, \quad \tilde{a}_{12} = e^{-1} \approx 0,3679, \quad (23)$$

$$d_{23} = 2, \quad \tilde{a}_{23} = e^{-2} \approx 0,1353, \quad (24)$$

$$d_{24} = 3, \quad \tilde{a}_{24} = e^{-3} \approx 0,0498. \quad (25)$$

Incluindo os self-loops, a matriz de pesos brutos è

$$\tilde{A} = \begin{bmatrix} 1 & 0,3679 & 0 & 0 \\ 0,3679 & 1 & 0,1353 & 0,0498 \\ 0 & 0,1353 & 1 & 0 \\ 0 & 0,0498 & 0 & 1 \end{bmatrix}. \quad (26)$$

Essa matriz è aplicada diretamente. Em particular, suas linhas não são divididas por 1,3679, 1,5530, 1,1353 e 1,0498.

9.3 Camada 1

Os parâmetros da primeira camada são

$$W^{(1)} = \begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} 2 \\ 1,5 \end{bmatrix}. \quad (27)$$

Para o nó v_1 , a agregação bruta è

$$\begin{aligned} A_{v_1}^{(1)} &= H_{v_1}^{(0)} + 0,3679 H_{v_2}^{(0)} \\ &= \begin{bmatrix} 30 \\ 80 \end{bmatrix} + 0,3679 \begin{bmatrix} 35 \\ 85 \end{bmatrix} \approx \begin{bmatrix} 42,8758 \\ 111,2698 \end{bmatrix}. \end{aligned} \quad (28)$$

Aplicando a combinação,

$$\begin{aligned} H_{v_1}^{(1)} &= \text{ReLU} \left(\begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix} \begin{bmatrix} 42,8758 \\ 111,2698 \end{bmatrix} + \begin{bmatrix} 2 \\ 1,5 \end{bmatrix} \right) \\ &\approx \begin{bmatrix} 67,9458 \\ 19,4664 \end{bmatrix}. \end{aligned} \quad (29)$$

Para os demais nós, obtém-se

$$\begin{aligned} A_{v_2}^{(1)} &\approx \begin{bmatrix} 50,7998 \\ 128,8341 \end{bmatrix}, & H_{v_2}^{(1)} &\approx \begin{bmatrix} 78,9335 \\ 22,1868 \end{bmatrix}, \\ A_{v_3}^{(1)} &\approx \begin{bmatrix} 30,7367 \\ 88,5035 \end{bmatrix}, & H_{v_3}^{(1)} &\approx \begin{bmatrix} 52,7698 \\ 16,1270 \end{bmatrix}, \\ A_{v_4}^{(1)} &\approx \begin{bmatrix} 26,7425 \\ 84,2319 \end{bmatrix}, & H_{v_4}^{(1)} &\approx \begin{bmatrix} 49,0640 \\ 15,6721 \end{bmatrix}. \end{aligned} \quad (30)$$

9.4 Camada 2

Os parâmetros da segunda camada são

$$W^{(2)} = \begin{bmatrix} -0,1 & 0,2 \\ 0,3 & 0,3 \end{bmatrix}, \quad b^{(2)} = \begin{bmatrix} 1,5 \\ 2,5 \end{bmatrix}. \quad (31)$$

Aplicando novamente os pesos brutos, resultam

$$\begin{aligned} A_{v_1}^{(2)} &\approx \begin{bmatrix} 96,9838 \\ 27,6285 \end{bmatrix}, & H_{v_1}^{(2)} &\approx \begin{bmatrix} 0 \\ 39,8837 \end{bmatrix}, \\ A_{v_2}^{(2)} &\approx \begin{bmatrix} 113,5138 \\ 32,3110 \end{bmatrix}, & H_{v_2}^{(2)} &\approx \begin{bmatrix} 0 \\ 46,2474 \end{bmatrix}, \\ A_{v_3}^{(2)} &\approx \begin{bmatrix} 63,4523 \\ 19,1297 \end{bmatrix}, & H_{v_3}^{(2)} &\approx \begin{bmatrix} 0 \\ 27,2746 \end{bmatrix}, \\ A_{v_4}^{(2)} &\approx \begin{bmatrix} 52,9939 \\ 16,7767 \end{bmatrix}, & H_{v_4}^{(2)} &\approx \begin{bmatrix} 0 \\ 23,4312 \end{bmatrix}. \end{aligned} \quad (32)$$

A primeira componente é zerada pela ReLU em todos os nós, pois os valores correspondentes antes da ativação são negativos.

9.5 Camada de saída e perda

Considere

$$W^{(\text{out})} = \begin{bmatrix} 0,7 & 0,6 \end{bmatrix}, \quad b^{(\text{out})} = 6. \quad (33)$$

As previsões são calculadas por

$$\hat{y}_{v_i} = W^{(\text{out})} H_{v_i}^{(2)} + b^{(\text{out})}. \quad (34)$$

Por exemplo,

$$\hat{y}_{v_1} = 0,7 \cdot 0 + 0,6 \cdot 39,8837 + 6 \approx 29,9302. \quad (35)$$

O conjunto completo de resultados è

Tabela 2: Predições usando apenas os pesos brutos.

Nó	Predição $\hat{y}_{v_i}$	Rótulo y_{v_i}
v_1	29,9302	20
v_2	33,7484	20
v_3	22,3648	22
v_4	20,0587	18

Usando a soma dos erros quadráticos,

$$\begin{aligned} \mathcal{L} &= \sum_{i=1}^4 (y_{v_i} - \hat{y}_{v_i})^2 \\ &\approx (20 - 29,9302)^2 + (20 - 33,7484)^2 + (22 - 22,3648)^2 + (18 - 20,0587)^2 \\ &\approx 292,0003. \end{aligned} \quad (36)$$

Com os mesmos parâmetros, as somas brutas ampliam as representações e a perda. Durante o treinamento, os pesos aprendidos podem se adaptar a essa escala.

9.6 Exemplo de atualização dos parâmetros de saída

O gradiente da perda em relação a cada predição è

$$\frac{\partial \mathcal{L}}{\partial \hat{y}_{v_i}} = 2 (\hat{y}_{v_i} - y_{v_i}). \quad (37)$$

Numericamente,

$$\left[\frac{\partial \mathcal{L}}{\partial \hat{y}_{v_1}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_2}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_3}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_4}} \right] \approx \begin{bmatrix} 19,8604 & 27,4969 & 0,7295 & 4,1174 \end{bmatrix}. \quad (38)$$

Os gradientes dos parâmetros de saída são

$$\frac{\partial \mathcal{L}}{\partial W^{(\text{out})}} \approx \begin{bmatrix} 0 & 2180,1405 \end{bmatrix}, \quad \frac{\partial \mathcal{L}}{\partial b^{(\text{out})}} \approx 52,2043. \quad (39)$$

Com taxa de aprendizado $\eta = 0,001$, um passo de descida do gradiente produz

$$W_{\text{novo}}^{(\text{out})} = W^{(\text{out})} - \eta \frac{\partial \mathcal{L}}{\partial W^{(\text{out})}} \approx \begin{bmatrix} 0,7 & -1,5801 \end{bmatrix}, \quad (40)$$

$$b_{\text{novo}}^{(\text{out})} = b^{(\text{out})} - \eta \frac{\partial \mathcal{L}}{\partial b^{(\text{out})}} \approx 5,9478. \quad (41)$$

O gradiente elevado evidencia a mudança de escala causada pelas somas brutas.