

Notação do framework de GNN com agregação ponderada pela distância

1 Objetivo

Este texto apresenta uma notação unificada para uma rede neural em grafos (Graph Neural Network, GNN) cuja agregação utiliza pesos de aresta definidos a partir da distância entre os nós. A notação adotada identifica explicitamente:

- o nó central, denotado por v_i ;
- a camada da GNN, denotada por k ;
- a agregação calculada para o nó v_i , denotada por $A_{v_i}^{(k)}$;
- a representação do nó v_i após a combinação, denotada por $H_{v_i}^{(k)}$;
- o vetor inicial de features, denotado por $H_{v_i}^{(0)} = X_{v_i}$;
- a saída obtida após a última camada, denotada por $\hat{y}_{v_i}$.

2 Grafo, vizinhança e dados dos nós

Seja $G = (V, E)$ um grafo, em que V é o conjunto de nós e E é o conjunto de arestas. Para um nó $v_i \in V$, define-se sua vizinhança por

$$\mathcal{N}(v_i) = \{v_j \in V : (v_i, v_j) \in E\}. \quad (1)$$

Como o modelo inclui uma autoaresta (self-loop) em cada nó, será conveniente usar a vizinhança estendida

$$\mathcal{N}^+(v_i) = \mathcal{N}(v_i) \cup \{v_i\}. \quad (2)$$

Cada nó possui dois tipos de informação que devem ser distinguidos:

- X_{v_i} : vetor de features fornecido como entrada da GNN;
- $\mathbf{x}_{v_i} \in \mathbb{R}^d$: vetor de posição utilizado para calcular as distâncias e os pesos das arestas.

Essa distinção evita usar o mesmo símbolo para as features do modelo e para as coordenadas espaciais dos nós.

3 Distância e peso das arestas

Para dois nós v_i e v_j , a distância euclidiana entre suas posições è

$$d_{ij} = \|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2 = \sqrt{\sum_{q=1}^d (x_{v_i,q} - x_{v_j,q})^2}. \quad (3)$$

O índice q percorre as coordenadas dos vetores de posição. Ele não deve ser confundido com k , que será reservado exclusivamente para indicar a camada da GNN.

O peso bruto entre v_i e v_j è definido por

$$\tilde{a}_{ij} = \begin{cases} \exp(-d_{ij}), & v_j \in \mathcal{N}(v_i), \\ 1, & v_j = v_i, \\ 0, & \text{caso contrário.} \end{cases} \quad (4)$$

Para uma aresta comum, o peso diminui à medida que a distância aumenta. Para a autoaresta, escolhe-se $\tilde{a}_{ii} = 1$, de modo que a informação do próprio nó participe da agregação.

4 Normalização por linha

O grau ponderado do nó v_i è a soma dos pesos brutos associados à sua vizinhança estendida:

$$s_{v_i} = \sum_{v_r \in \mathcal{N}^+(v_i)} \tilde{a}_{ir}. \quad (5)$$

O símbolo r è apenas um índice de soma. Seu uso evita o conflito que ocorreria se k representasse simultaneamente uma camada e um índice de nó. O peso normalizado da mensagem enviada por v_j ao nó v_i è

$$a_{ij}^{(\text{norm})} = \frac{\tilde{a}_{ij}}{s_{v_i}}. \quad (6)$$

Consequentemente,

$$\sum_{v_j \in \mathcal{N}^+(v_i)} a_{ij}^{(\text{norm})} = 1. \quad (7)$$

Assim, a agregação è uma média ponderada das representações na vizinhança estendida de v_i .

5 Representações nas camadas da GNN

5.1 Inicialização

A representação inicial do nó v_i è seu vetor de features:

$$H_{v_i}^{(0)} = X_{v_i}. \quad (8)$$

O sobrescrito (0) indica que nenhuma camada de passagem de mensagens foi aplicada. Em geral, $H_{v_i}^{(k-1)}$ representa a informação disponível no nó v_i antes da camada k , enquanto $H_{v_i}^{(k)}$ representa a informação produzida por essa camada.

5.2 Agregação

Para $k = 1, 2, \dots, K$, define-se formalmente

$$A_{v_i}^{(k)} = \text{AGG}^{(k)} \left(\left\{ H_{v_j}^{(k-1)} : v_j \in \mathcal{N}^+(v_i) \right\} \right). \quad (9)$$

No modelo ponderado pela distância, a função de agregação é

$$A_{v_i}^{(k)} = \sum_{v_j \in \mathcal{N}^+(v_i)} \frac{\tilde{a}_{ij}}{s_{v_i}} H_{v_j}^{(k-1)}. \quad (10)$$

Substituindo a definição de s_{v_i} da Equação (5), resulta

$$A_{v_i}^{(k)} = \sum_{v_j \in \mathcal{N}^+(v_i)} \frac{\tilde{a}_{ij}}{\sum_{v_r \in \mathcal{N}^+(v_i)} \tilde{a}_{ir}} H_{v_j}^{(k-1)}. \quad (11)$$

Separando a autoaresta das arestas comuns e usando $\tilde{a}_{ii} = 1$ e $\tilde{a}_{ij} = \exp(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2)$, obtém-se

$$A_{v_i}^{(k)} = \frac{H_{v_i}^{(k-1)} + \sum_{v_j \in \mathcal{N}(v_i)} \exp(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2) H_{v_j}^{(k-1)}}{1 + \sum_{v_r \in \mathcal{N}(v_i)} \exp(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_r}\|_2)}. \quad (12)$$

A Equação (12) mostra que um vizinho próximo possui maior participação na agregação do que um vizinho distante. O termo $H_{v_i}^{(k-1)}$ preserva parte da representação anterior do próprio nó.

5.3 Combinação

Depois da agregação, a representação do nó é atualizada por

$$H_{v_i}^{(k)} = \text{COMB}^{(k)} \left\{ H_{v_i}^{(k-1)}, A_{v_i}^{(k)} \right\}. \quad (13)$$

Na implementação considerada, a combinação corresponde a uma transformação linear seguida da ativação ReLU:

$$H_{v_i}^{(k)} = \text{ReLU} \left(W^{(k)} A_{v_i}^{(k)} + b^{(k)} \right), \quad (14)$$

em que $W^{(k)}$ e $b^{(k)}$ são, respectivamente, a matriz de pesos e o vetor de viés aprendidos na camada k . Embora $H_{v_i}^{(k-1)}$ não apareça como argumento separado no lado direito da Equação (14), ele já está contido em $A_{v_i}^{(k)}$ por meio da autoaresta.

Substituindo a agregação, a atualização completa da camada k è

$$H_{v_i}^{(k)} = \text{ReLU} \left[W^{(k)} \left(\sum_{v_j \in \mathcal{N}^+(v_i)} \frac{\tilde{a}_{ij}}{\sum_{v_r \in \mathcal{N}^+(v_i)} \tilde{a}_{ir}} H_{v_j}^{(k-1)} \right) + b^{(k)} \right]. \quad (15)$$

6 Saída da rede

Após K camadas, $H_{v_i}^{(K)}$ è a representação final do nó. Se o modelo possuir uma camada de leitura linear, a saída será

$$\hat{y}_{v_i} = W^{(\text{out})} H_{v_i}^{(K)} + b^{(\text{out})}. \quad (16)$$

Se a última representação já possuir a dimensão da variável de interesse, pode-se adotar diretamente

$$\hat{y}_{v_i} = H_{v_i}^{(K)}. \quad (17)$$

7 Correspondência entre as notações

A relação entre a notação baseada nos índices i e ℓ e a notação baseada em v_i e k è resumida na Tabela 1.

Tabela 1: Correspondência entre as notações dos dois frameworks.

Notação anterior	Notação unificada	Interpretação
$h_i^{(\ell)}$	$H_{v_i}^{(k-1)}$	representação antes da camada k
$\bar{h}_i$	$A_{v_i}^{(k)}$	agregação recebida pelo nó v_i
$h_i^{(\ell+1)}$	$H_{v_i}^{(k)}$	representação depois da camada k
$W^{(\ell)}$	$W^{(k)}$	matriz de pesos da camada k
$b^{(\ell)}$	$b^{(k)}$	vetor de viés da camada k
$\tilde{A}_{ij}$	$\tilde{a}_{ij}$	peso bruto da aresta (v_i, v_j)
s_i	s_{v_i}	grau ponderado do nó v_i

8 Framework final resumido

Para cada nó v_i , inicializa-se

$$H_{v_i}^{(0)} = X_{v_i}. \quad (18)$$

Em seguida, para cada camada $k = 1, 2, \dots, K$, calculam-se

$$A_{v_i}^{(k)} = \sum_{v_j \in \mathcal{N}^+(v_i)} \frac{\tilde{a}_{ij}}{\sum_{v_r \in \mathcal{N}^+(v_i)} \tilde{a}_{ir}} H_{v_j}^{(k-1)}, \quad (19)$$

$$H_{v_i}^{(k)} = \text{ReLU}\left(W^{(k)} A_{v_i}^{(k)} + b^{(k)}\right), \quad (20)$$

com

$$\tilde{a}_{ij} = \begin{cases} \exp\left(-\|\mathbf{x}_{v_i} - \mathbf{x}_{v_j}\|_2\right), & v_j \in \mathcal{N}(v_i), \\ 1, & v_j = v_i, \\ 0, & \text{caso contrário.} \end{cases} \quad (21)$$

Finalmente, a saída do nó v_i é calculada a partir de sua representação na última camada, $H_{v_i}^{(K)}$.

9 Exemplo numérico

Este exemplo utiliza a mesma estrutura geral do exemplo da Seção 4.2 de *NotesGNN*: quatro nós, duas features por nó, duas camadas de GNN e uma camada linear de saída. A diferença é que, aqui, a agregação considera os pesos das arestas calculados a partir das distâncias.

9.1 Grafo, features e posições

Considere o conjunto de nós

$$V = \{v_1, v_2, v_3, v_4\} \quad (22)$$

e o conjunto de arestas não direcionadas

$$E = \{(v_1, v_2), (v_2, v_3), (v_2, v_4)\}. \quad (23)$$

As features de entrada e os rótulos são

$$X_{v_1} = \begin{bmatrix} 30 \\ 80 \end{bmatrix}, \quad X_{v_2} = \begin{bmatrix} 35 \\ 85 \end{bmatrix}, \quad X_{v_3} = \begin{bmatrix} 26 \\ 77 \end{bmatrix}, \quad X_{v_4} = \begin{bmatrix} 25 \\ 80 \end{bmatrix}, \quad (24)$$

$$y_{v_1} = 20, \quad y_{v_2} = 20, \quad y_{v_3} = 22, \quad y_{v_4} = 18. \quad (25)$$

Para tornar o cálculo dos pesos explícito, atribuem-se aos nós as posições

$$\mathbf{x}_{v_1} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_2} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_3} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}, \quad \mathbf{x}_{v_4} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}. \quad (26)$$

Essas coordenadas são usadas somente para determinar os pesos das arestas. Elas não substituem os vetores de features X_{v_i} .

9.2 Distâncias e matriz de pesos

As distâncias associadas às três arestas são

$$d_{12} = \|\mathbf{x}_{v_1} - \mathbf{x}_{v_2}\|_2 = 1, \quad \tilde{a}_{12} = e^{-1} \approx 0,3679, \quad (27)$$

$$d_{23} = \|\mathbf{x}_{v_2} - \mathbf{x}_{v_3}\|_2 = 2, \quad \tilde{a}_{23} = e^{-2} \approx 0,1353, \quad (28)$$

$$d_{24} = \|\mathbf{x}_{v_2} - \mathbf{x}_{v_4}\|_2 = 3, \quad \tilde{a}_{24} = e^{-3} \approx 0,0498. \quad (29)$$

Incluindo os self-loops, cujos pesos são unitários, a matriz de pesos brutos è

$$\tilde{A} = \begin{bmatrix} 1 & 0,3679 & 0 & 0 \\ 0,3679 & 1 & 0,1353 & 0,0498 \\ 0 & 0,1353 & 1 & 0 \\ 0 & 0,0498 & 0 & 1 \end{bmatrix}. \quad (30)$$

Os graus ponderados são

$$\begin{bmatrix} s_{v_1} & s_{v_2} & s_{v_3} & s_{v_4} \end{bmatrix} \approx \begin{bmatrix} 1,3679 & 1,5530 & 1,1353 & 1,0498 \end{bmatrix}. \quad (31)$$

Para abreviar os cálculos numéricos, denote por $P = (p_{ij})$ a matriz dos pesos normalizados por linha, em que $p_{ij} = \tilde{a}_{ij}/s_{v_i}$. Assim,

$$P \approx \begin{bmatrix} 0,7311 & 0,2689 & 0 & 0 \\ 0,2369 & 0,6439 & 0,0871 & 0,0321 \\ 0 & 0,1192 & 0,8808 & 0 \\ 0 & 0,0474 & 0 & 0,9526 \end{bmatrix}. \quad (32)$$

Cada linha de P soma 1. Note, por exemplo, que a contribuição de v_3 para v_2 è maior que a contribuição de v_4 , pois $d_{23} < d_{24}$.

9.3 Camada 1

Os parâmetros da primeira camada são

$$W^{(1)} = \begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} 2 \\ 1,5 \end{bmatrix}. \quad (33)$$

Para o nó v_1 , a vizinhança estendida è $\mathcal{N}^+(v_1) = \{v_1, v_2\}$. Portanto,

$$\begin{aligned} A_{v_1}^{(1)} &= 0,7311H_{v_1}^{(0)} + 0,2689H_{v_2}^{(0)} \\ &= 0,7311 \begin{bmatrix} 30 \\ 80 \end{bmatrix} + 0,2689 \begin{bmatrix} 35 \\ 85 \end{bmatrix} \approx \begin{bmatrix} 31,3447 \\ 81,3447 \end{bmatrix}. \end{aligned} \quad (34)$$

Aplicando a combinação,

$$\begin{aligned}
H_{v_1}^{(1)} &= \text{ReLU} \left(\begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix} \begin{bmatrix} 31,3447 \\ 81,3447 \end{bmatrix} + \begin{bmatrix} 2 \\ 1,5 \end{bmatrix} \right) \\
&\approx \begin{bmatrix} 50,2102 \\ 14,6345 \end{bmatrix}.
\end{aligned} \tag{35}$$

Repetindo o procedimento para os demais nós, obtém-se

$$\begin{aligned}
A_{v_2}^{(1)} &\approx \begin{bmatrix} 32,7107 \\ 82,9581 \end{bmatrix}, & H_{v_2}^{(1)} &\approx \begin{bmatrix} 51,5386 \\ 14,8206 \end{bmatrix}, \\
A_{v_3}^{(1)} &\approx \begin{bmatrix} 27,0728 \\ 77,9536 \end{bmatrix}, & H_{v_3}^{(1)} &\approx \begin{bmatrix} 46,7179 \\ 14,3834 \end{bmatrix}, \\
A_{v_4}^{(1)} &\approx \begin{bmatrix} 25,4743 \\ 80,2371 \end{bmatrix}, & H_{v_4}^{(1)} &\approx \begin{bmatrix} 46,8320 \\ 15,0000 \end{bmatrix}.
\end{aligned} \tag{36}$$

9.4 Camada 2

Na segunda camada, a mesma matriz de pesos normalizados P agrega as representações produzidas pela primeira camada. Os parâmetros são

$$W^{(2)} = \begin{bmatrix} -0,1 & 0,2 \\ 0,3 & 0,3 \end{bmatrix}, \quad b^{(2)} = \begin{bmatrix} 1,5 \\ 2,5 \end{bmatrix}. \tag{37}$$

As agregações e representações da segunda camada são

$$\begin{aligned}
A_{v_1}^{(2)} &\approx \begin{bmatrix} 50,5675 \\ 14,6845 \end{bmatrix}, & H_{v_1}^{(2)} &\approx \begin{bmatrix} 0 \\ 22,0756 \end{bmatrix}, \\
A_{v_2}^{(2)} &\approx \begin{bmatrix} 50,6529 \\ 14,7441 \end{bmatrix}, & H_{v_2}^{(2)} &\approx \begin{bmatrix} 0 \\ 22,1191 \end{bmatrix}, \\
A_{v_3}^{(2)} &\approx \begin{bmatrix} 47,2925 \\ 14,4355 \end{bmatrix}, & H_{v_3}^{(2)} &\approx \begin{bmatrix} 0 \\ 21,0184 \end{bmatrix}, \\
A_{v_4}^{(2)} &\approx \begin{bmatrix} 47,0552 \\ 14,9915 \end{bmatrix}, & H_{v_4}^{(2)} &\approx \begin{bmatrix} 0 \\ 21,1140 \end{bmatrix}.
\end{aligned} \tag{38}$$

A primeira componente é igual a zero para todos os nós porque o valor pré-ativação correspondente é negativo e, portanto, é anulado pela ReLU.

9.5 Camada de saída e perda

Considere a camada linear de saída

$$W^{(\text{out})} = \begin{bmatrix} 0,7 & 0,6 \end{bmatrix}, \quad b^{(\text{out})} = 6. \tag{39}$$

As predições são calculadas por

$$\hat{y}_{v_i} = W^{(\text{out})} H_{v_i}^{(2)} + b^{(\text{out})}. \quad (40)$$

Por exemplo,

$$\hat{y}_{v_1} = 0,7 \cdot 0 + 0,6 \cdot 22,0756 + 6 \approx 19,2454. \quad (41)$$

O conjunto completo de resultados è

Tabela 2: Predições do exemplo numérico.

Nó	Predição $\hat{y}_{v_i}$	Rótulo y_{v_i}
v_1	19,2454	20
v_2	19,2715	20
v_3	18,6111	22
v_4	18,6684	18

Usando a soma dos erros quadráticos,

$$\begin{aligned} \mathcal{L} &= \sum_{i=1}^4 (y_{v_i} - \hat{y}_{v_i})^2 \\ &\approx (20 - 19,2454)^2 + (20 - 19,2715)^2 + (22 - 18,6111)^2 + (18 - 18,6684)^2 \\ &\approx 13,0320. \end{aligned} \quad (42)$$

9.6 Exemplo de atualização dos parâmetros de saída

Para ilustrar um passo de retropropagação, o gradiente da perda em relação a cada predição è

$$\frac{\partial \mathcal{L}}{\partial \hat{y}_{v_i}} = 2 (\hat{y}_{v_i} - y_{v_i}). \quad (43)$$

Numericamente,

$$\left[\frac{\partial \mathcal{L}}{\partial \hat{y}_{v_1}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_2}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_3}} \quad \frac{\partial \mathcal{L}}{\partial \hat{y}_{v_4}} \right] \approx \begin{bmatrix} -1,5093 & -1,4570 & -6,7779 & 1,3368 \end{bmatrix}. \quad (44)$$

Os gradientes dos parâmetros de saída são

$$\frac{\partial \mathcal{L}}{\partial W^{(\text{out})}} \approx \begin{bmatrix} 0 & -179,7822 \end{bmatrix}, \quad \frac{\partial \mathcal{L}}{\partial b^{(\text{out})}} \approx -8,4074. \quad (45)$$

Com taxa de aprendizado $\eta = 0,001$, um passo de descida do gradiente produz

$$W_{\text{novo}}^{(\text{out})} = W^{(\text{out})} - \eta \frac{\partial \mathcal{L}}{\partial W^{(\text{out})}} \approx \begin{bmatrix} 0,7 & 0,7798 \end{bmatrix}, \quad (46)$$

$$b_{\text{novo}}^{(\text{out})} = b^{(\text{out})} - \eta \frac{\partial \mathcal{L}}{\partial b^{(\text{out})}} \approx 6,0084. \quad (47)$$

A retropropagação prossegue analogamente pelas duas camadas ocultas.