

Notas de Redes Neurais em Grafos

Lorenzo C. Lima

2026

Contents

1	Fundamentos básicos de GNNs	2
1.1	Representation Learning	2
1.2	Objetivo das GNNs	2
1.3	Tipos de tarefas	2
1.3.1	Nível de nó	2
1.3.2	Nível de aresta	2
1.3.3	Nível de grafo	2
1.4	Construção do grafo (Graph Construction)	2
1.4.1	Dados de entrada com estruturas explícitas do grafo	2
1.4.2	Dados de entrada com estruturas implícitas do grafo	2
1.5	Tipos de aprendizado	2
1.5.1	Aprendizado transdutivo	2
1.5.2	Aprendizado indutivo	3
2	Background e definição do problema de GNNs	3
2.1	Elementos	3
2.2	Objetivo	4
3	Funcionamento de uma Rede Neural	4
3.1	Exemplo algébrico	4
3.2	Exemplo numérico	6
4	Framework geral da GNN	8
4.1	Framework	8
4.2	Exemplo	9
5	Grafo $k=2$ e $k=3$	13
6	Resultados obtidos	14
7	Adaptação para GCN (03/06/2026)	20
8	Framework geral da GCN	25
8.1	Exemplo	26
8.1.1	Camada 1	26
8.1.2	Camada 2	27
8.1.3	Camada de saída	27

1 Fundamentos básicos de GNNs

1.1 Representation Learning

Aprender uma transformação dos dados para um espaço onde a estrutura relevante torna-se mais simples.

1.2 Objetivo das GNNs

Atualizar iterativamente as representações dos nós vizinhos e sua representação própria na iteração anterior. Podemos classificar em dois tipos:

- GNN supervisionada: há rótulos, a GNN aprende uma função

$$f_{\theta}(G, X) \rightarrow Y$$

onde G é o grafo, X são as features e Y é o rótulo, seja ele associado aos nós, às arestas ou ao próprio grafo.

- GNN não-supervisionada: não há rótulos, ocorre o aprendizado de uma representação/estruturas do grafo G , baseado apenas nas features.

1.3 Tipos de tarefas

1.3.1 Nível de nó

A tarefa a nível de nó prevê algo para cada nó, como se fosse um foco local.

1.3.2 Nível de aresta

A tarefa a nível de aresta prevê algo para cada conexão entre nós, buscando tratar sobre relações entre os mesmos.

1.3.3 Nível de grafo

A tarefa a nível de grafo faz previsões para o grafo como um todo, visando buscar características gerais.

1.4 Construção do grafo (Graph Construction)

A construção do grafo é importante para capturar dependências entre os objetos nos dados de entrada. Existem dois tipos de maneiras para lidar com construção de grafos.

1.4.1 Dados de entrada com estruturas explícitas do grafo

- O grafo já existe
- A estrutura do grafo já é definida: Tome a representação do grafo por

$$G = (V, E, X, A)$$

sendo V os vértices/nós, E as arestas, X como a matriz de features dos nós e A a matriz de adjacências atrelada ao grafo. Todas as informações de G já são representadas no problema.

1.4.2 Dados de entrada com estruturas implícitas do grafo

Neste caso, tome a mesma estrutura acima. Quando a estrutura é implícita, E não é apresentado a nós no problema, e consequentemente, A também não. Dessa forma o grafo deve ser descoberto. Existem várias estratégias para construir o grafo. No caso do projeto, usa-se um grid (malha de pontos) para estabelecer a localização e as relações das estações meteorológicas dentro do grafo.

1.5 Tipos de aprendizado

1.5.1 Aprendizado transdutivo

Todos os nós do grafo de treino são vistos, mas não são vistos os rótulos dos nós de teste.

1.5.2 Aprendizado indutivo

O modelo vê apenas um subconjunto de nós.




Figure 1: Comparação entre aprendizado transdutivo e indutivo

2 Background e definição do problema de GNNs


O problema de Redes Neurais em Grafos pode ser definido da seguinte maneira:

2.1 Elementos

- $G = (V, E)$ o grafo G , com V como o conjunto de vértices e E o conjunto de arestas.
- $A \in \mathbb{R}^{n \times n}$ como a matriz de adjacências. Ela é definida da seguinte maneira, dado n o número de nós do grafo G :

$$A = (a_{ij}) = \begin{cases} 1, & \text{se } (i, j) \in E \rightarrow \text{os vértices } i \text{ e } j \text{ possuem ligação} \\ 0, & \text{caso contrário} \end{cases}$$

Exemplo: Tome o grafo G abaixo:



$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

- $X \in \mathbb{R}^{n \times C}$ é a matriz de features dos nós, contendo a informação inicial. C é o número de features de cada nó.

Exemplo:

$$x_1 = [1 \ 3 \ 4 \ 5], \ x_2 = [2 \ 0 \ 4 \ 3], \ x_3 = [1 \ 1 \ 1 \ 1]$$

$$X = \begin{bmatrix} 1 & 3 & 4 & 5 \\ 2 & 0 & 4 & 3 \\ 1 & 1 & 1 & 1 \end{bmatrix}_{n \times C}$$

- k é o número de camadas da GNN.

2.2 Objetivo


Aprender representações efetivas dos nós, denotadas por $H \in \mathbb{R}^{n \times F}$, onde F é a dimensão dessas representações efetivas, que combinam a estrutura do grafo e suas features. A representação é chamada de *embedding*, e sua função é representar o nó do grafo num vetor de dimensão menor tal que a estrutura do grafo se preserve.

3 Funcionamento de uma Rede Neural

Nesta seção, será mostrado o funcionamento de uma rede neural "vanilla". Será apresentado um modelo utilizando um vetor de entrada $x = [x_1, x_2]$, buscando obter um valor de saída previsto dado por $\hat{y}$.

A rede neural terá duas camadas ocultas, cuja função de ativação utilizada será a *ReLU*. Para a saída, será usada a função identidade.

3.1 Exemplo algébrico



Chamemos o vetor de entrada de

$$H^{(0)} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_{2 \times 1}$$

visto que temos duas componentes nesse vetor.

Além disso, temos matrizes W referentes aos pesos fornecidos nas camadas da rede neural. Existe uma matriz de pesos para cada camada, e suas dimensões dependerão da quantidade de neurônios da camada seguinte ou do tamanho do vetor de saída. Nesse caso, temos:

$$W^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix}_{2 \times 2}, W^{(2)} = \begin{bmatrix} w_{11}^{(2)} & w_{12}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} \end{bmatrix}_{2 \times 2}, W^{(3)} = \begin{bmatrix} w_1^{(3)} & w_2^{(3)} \end{bmatrix}_{1 \times 2}$$

Também temos os vieses, que passam por cada camada, dados por

$$b^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix}_{2 \times 1}, b^{(2)} = \begin{bmatrix} b_1^{(2)} \\ b_2^{(2)} \end{bmatrix}_{2 \times 1}, b^{(3)} = b_1^{(3)}$$

Partindo para a primeira camada:

$$W^{(1)}H^{(0)} + b^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix} = \begin{bmatrix} w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)} \\ w_{21}^{(1)}x_1 + w_{22}^{(1)}x_2 + b_2^{(1)} \end{bmatrix}$$

Defina

$$\begin{bmatrix} z_1^{(1)} \\ z_2^{(1)} \end{bmatrix} = \begin{bmatrix} w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)} \\ w_{21}^{(1)}x_1 + w_{22}^{(1)}x_2 + b_2^{(1)} \end{bmatrix}$$

Aplicando *ReLU* em $z^{(1)}$:

$$\begin{bmatrix} ReLU(z_1^{(1)}) \\ ReLU(z_2^{(1)}) \end{bmatrix} = \begin{bmatrix} \max(0, z_1^{(1)}) \\ \max(0, z_2^{(1)}) \end{bmatrix} = \begin{bmatrix} h_1^{(1)} \\ h_2^{(1)} \end{bmatrix} = H^{(1)}$$

Repetimos o processo para a segunda camada:

$$W^{(2)}H^{(1)} + b^{(2)} = \begin{bmatrix} w_{11}^{(2)} & w_{12}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} \end{bmatrix} \begin{bmatrix} h_1^{(1)} \\ h_2^{(1)} \end{bmatrix} + \begin{bmatrix} b_1^{(2)} \\ b_2^{(2)} \end{bmatrix} = \begin{bmatrix} w_{11}^{(2)}h_1^{(1)} + w_{12}^{(2)}h_2^{(1)} + b_1^{(2)} \\ w_{21}^{(2)}h_1^{(1)} + w_{22}^{(2)}h_2^{(1)} + b_2^{(2)} \end{bmatrix}$$

Defina

$$\begin{bmatrix} z_1^{(2)} \\ z_2^{(2)} \end{bmatrix} = \begin{bmatrix} w_{11}^{(2)}h_1^{(1)} + w_{12}^{(2)}h_2^{(1)} + b_1^{(2)} \\ w_{21}^{(2)}h_1^{(1)} + w_{22}^{(2)}h_2^{(1)} + b_2^{(2)} \end{bmatrix}$$

Aplicando *ReLU* em $z^{(2)}$:

$$\begin{bmatrix} ReLU(z_1^{(2)}) \\ ReLU(z_2^{(2)}) \end{bmatrix} = \begin{bmatrix} \max(0, z_1^{(2)}) \\ \max(0, z_2^{(2)}) \end{bmatrix} = \begin{bmatrix} h_1^{(2)} \\ h_2^{(2)} \end{bmatrix} = H^{(2)}$$

Para a última camada:

$$W^{(3)}H^{(2)} + b^{(3)} = \begin{bmatrix} w_1^{(3)} & w_2^{(3)} \end{bmatrix} \begin{bmatrix} h_1^{(2)} \\ h_2^{(2)} \end{bmatrix} + b^{(3)} = w_1^{(3)}h_1^{(2)} + w_2^{(3)}h_2^{(2)} + b^{(3)} = z^{(3)} \rightarrow \hat{y}$$

Agora, vamos tomar uma função de perda e fazer o "backpropagation".

Perda (Erro Quadrático Médio):

$$L = (y - \hat{y})^2$$

$$\frac{\partial L}{\partial \hat{y}} = -2(\hat{y} - y) \cdot (-1) = -2(y - \hat{y})$$

Erro na saída, definimos como:

$$\delta^{(3)} = -2(\hat{y} - y)$$

Gradientes dos pesos da camada 3:

$$\frac{\partial L}{\partial w_j^{(3)}} = \delta^{(3)} \cdot a_j^{(2)}, \quad j = 1, 2$$

$$\frac{\partial L}{\partial b^{(3)}} = \delta^{(3)}$$

Retropropagação para a camada oculta 2:

$$\delta_j^{(2)} = w_j^{(3)} \cdot \delta^{(3)} \cdot ReLU'(z_j^{(2)}), \quad j = 1, 2$$

De forma que

$$ReLU'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

Gradientes dos pesos da camada 2:

$$\frac{\partial L}{\partial w_{jk}^{(2)}} = \delta_j^{(2)} \cdot a_k^{(1)}, \quad j = 1, 2; \quad k = 1, 2$$

$$\frac{\partial L}{\partial b_j^{(2)}} = \delta_j^{(2)}$$

Retropropagação para a camada oculta 1:

$$\delta_k^{(1)} = \left(\sum_{j=1}^2 w_{jk}^{(2)} \cdot \delta_j^{(2)} \right) \cdot \text{ReLU}'(z_k^{(1)}), \quad k = 1, 2$$

Expandindo:

$$\begin{aligned} \delta_1^{(1)} &= (w_{11}^{(2)} \delta_1^{(2)} + w_{21}^{(2)} \delta_2^{(2)}) \cdot \text{ReLU}'(z_1^{(1)}) \\ \delta_2^{(1)} &= (w_{12}^{(2)} \delta_1^{(2)} + w_{22}^{(2)} \delta_2^{(2)}) \cdot \text{ReLU}'(z_2^{(1)}) \end{aligned}$$

Gradientes dos pesos da camada 1:

$$\frac{\partial L}{\partial w_{ki}^{(1)}} = \delta_k^{(1)} \cdot x_i, \quad k = 1, 2; \quad i = 1, 2$$

$$\frac{\partial L}{\partial b_k^{(1)}} = \delta_k^{(1)}$$

Para cada peso θ da rede:

$$\theta \leftarrow \theta - \eta \frac{\partial L}{\partial \theta}$$

onde η é uma taxa de aprendizado.

3.2 Exemplo numérico

Camada 1:

$$\begin{aligned} w_{11}^{(1)} &= 0,3 & w_{12}^{(1)} &= 0,2 & w_{21}^{(1)} &= -0,1 & w_{22}^{(1)} &= 0,5 \\ b_1^{(1)} &= 2 & b_2^{(1)} &= 3 \end{aligned}$$

Camada 2:

$$\begin{aligned} w_{11}^{(2)} &= 0,4 & w_{12}^{(2)} &= -0,1 & w_{21}^{(2)} &= 0,3 & w_{22}^{(2)} &= 0,5 \\ b_1^{(2)} &= 1 & b_2^{(2)} &= 2 \end{aligned}$$

Camada 3:

$$w_1^{(3)} = 0,3 \quad w_2^{(3)} = 0,2 \quad b^{(3)} = 2$$

Entrada:

$$H^{(0)} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} T_i \\ U_i \end{bmatrix} = \begin{bmatrix} 25 \\ 80 \end{bmatrix}$$

1º) $W^{(1)}H^{(0)} + b^{(1)} = z^{(1)}$

$$\begin{aligned} \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix} &= \begin{bmatrix} w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)} \\ w_{21}^{(1)}x_1 + w_{22}^{(1)}x_2 + b_2^{(1)} \end{bmatrix} \\ &= \begin{bmatrix} 0,3 \cdot 25 + 0,2 \cdot 80 + 2 \\ -0,1 \cdot 25 + 0,5 \cdot 80 + 3 \end{bmatrix} = \begin{bmatrix} 25,5 \\ 40,5 \end{bmatrix} \end{aligned}$$

$$a_1^{(1)} = \text{ReLU}(z_1^{(1)}) = \max(0, 25,5) = 25,5$$

$$a_2^{(1)} = \text{ReLU}(z_2^{(1)}) = \max(0, 40,5) = 40,5$$

$$\Rightarrow \begin{bmatrix} a_1^{(1)} \\ a_2^{(1)} \end{bmatrix} = \begin{bmatrix} 25,5 \\ 40,5 \end{bmatrix}$$

2º) $W^{(2)}H^{(1)} + b^{(2)} = z^{(2)}$

$$\begin{bmatrix} w_{11}^{(2)} & w_{12}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} \end{bmatrix} \begin{bmatrix} a_1^{(1)} \\ a_2^{(1)} \end{bmatrix} + \begin{bmatrix} b_1^{(2)} \\ b_2^{(2)} \end{bmatrix} = \begin{bmatrix} 0,4 \cdot 25,5 + (-0,1) \cdot 40,5 + 1 \\ 0,3 \cdot 25,5 + 0,5 \cdot 40,5 + 2 \end{bmatrix} = \begin{bmatrix} 7,15 \\ 29,9 \end{bmatrix}$$

$$a_1^{(2)} = \text{ReLU}(z_1^{(2)}) = 7,15$$

$$a_2^{(2)} = \text{ReLU}(z_2^{(2)}) = 29,9$$

$$3^{\text{o}}) W^{(3)}H^{(2)} + b^{(3)} = z^{(3)}$$

$$\begin{bmatrix} w_1^{(3)} & w_2^{(3)} \end{bmatrix} \begin{bmatrix} a_1^{(2)} \\ a_2^{(2)} \end{bmatrix} + b^{(3)} = z^{(3)}$$

$$z^{(3)} = w_1^{(3)}a_1^{(2)} + w_2^{(3)}a_2^{(2)} + b^{(3)} = 0,3 \cdot 7,15 + 0,2 \cdot 29,9 + 2 = 10,125$$

$$\hat{y} = \text{ReLU}(z^{(3)}) = 10,125$$

Agora que temos $\hat{y}$, vamos usar $y = 9$ e recalibrar a rede. Utilizando a função de perda $L = (y - \hat{y})^2$:

$$\frac{\partial L}{\partial \hat{y}} = -2(y - \hat{y}) = 2(\hat{y} - y) = 2(10,125 - 9) = 2(1,125) = 2,25$$

Definimos $\delta^{(3)} = \frac{\partial L}{\partial \hat{y}} = 2,25$ como o erro na camada 3.

Gradientes dos pesos da camada 3:

$$\frac{\partial L}{\partial w_1^{(3)}} = \delta^{(3)} \cdot a_1^{(2)} = 2,25 \cdot 7,15 = 16,0875$$

$$\frac{\partial L}{\partial w_2^{(3)}} = \delta^{(3)} \cdot a_2^{(2)} = 2,25 \cdot 29,9 = 67,275$$

$$\frac{\partial L}{\partial b^{(3)}} = \delta^{(3)} = 2,25$$

Retropropagação para a camada 2:

$$\delta_1^{(2)} = w_1^{(3)} \cdot \delta^{(3)} \cdot \text{ReLU}'(z_1^{(2)}) = 0,3 \cdot 2,25 \cdot 1 = 0,675$$

$$\delta_2^{(2)} = w_2^{(3)} \cdot \delta^{(3)} \cdot \text{ReLU}'(z_2^{(2)}) = 0,2 \cdot 2,25 \cdot 1 = 0,45$$

Onde

$$\text{ReLU}'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

Gradientes dos pesos da camada 2:

$$\frac{\partial L}{\partial w_{11}^{(2)}} = \delta_1^{(2)} \cdot a_1^{(1)} = 0,675 \cdot 25,5 = 17,2125$$

$$\frac{\partial L}{\partial w_{12}^{(2)}} = \delta_1^{(2)} \cdot a_2^{(1)} = 0,675 \cdot 40,5 = 27,3375$$

$$\frac{\partial L}{\partial w_{21}^{(2)}} = \delta_2^{(2)} \cdot a_1^{(1)} = 0,45 \cdot 25,5 = 11,475$$

$$\frac{\partial L}{\partial w_{22}^{(2)}} = \delta_2^{(2)} \cdot a_2^{(1)} = 0,45 \cdot 40,5 = 18,225$$

$$\frac{\partial L}{\partial b_1^{(2)}} = \delta_1^{(2)} = 0,675 \quad \frac{\partial L}{\partial b_2^{(2)}} = \delta_2^{(2)} = 0,45$$

Retropropagação para a camada 1:

$$\delta_1^{(1)} = \left(w_{11}^{(2)} \delta_1^{(2)} + w_{21}^{(2)} \delta_2^{(2)} \right) \cdot \text{ReLU}'\left(z_1^{(1)}\right)$$

$$\delta_2^{(1)} = \left(w_{12}^{(2)} \delta_1^{(2)} + w_{22}^{(2)} \delta_2^{(2)} \right) \cdot \text{ReLU}'\left(z_2^{(1)}\right)$$

$$\delta_1^{(1)} = (0,4 \cdot 0,675 + 0,3 \cdot 0,45) \cdot 1 = 0,405$$

$$\delta_2^{(1)} = (-0,1 \cdot 0,675 + 0,5 \cdot 0,45) \cdot 1 = 0,1575$$

Gradientes dos pesos da camada 1:

$$\frac{\partial L}{\partial w_{11}^{(1)}} = \delta_1^{(1)} \cdot x_1 = 0,405 \cdot 25 = 10,125$$

$$\frac{\partial L}{\partial w_{12}^{(1)}} = \delta_1^{(1)} \cdot x_2 = 0,405 \cdot 80 = 32,4$$

$$\frac{\partial L}{\partial w_{21}^{(1)}} = \delta_2^{(1)} \cdot x_1 = 0,1575 \cdot 25 = 3,9375$$

$$\frac{\partial L}{\partial w_{22}^{(1)}} = \delta_2^{(1)} \cdot x_2 = 0,1575 \cdot 80 = 12,6$$

$$\frac{\partial L}{\partial b_1^{(1)}} = \delta_1^{(1)} = 0,405 \quad \frac{\partial L}{\partial b_2^{(1)}} = \delta_2^{(1)} = 0,1575$$

Atualização dos pesos:

Para cada peso θ da rede:

$$\theta \leftarrow \theta - \eta \frac{\partial L}{\partial \theta}$$

onde η é a taxa de aprendizado. Tome $\eta = 0,01$.

Exemplos de atualização:

$$w_{11}^{(1)} \leftarrow w_{11}^{(1)} - \eta \cdot \frac{\partial L}{\partial w_{11}^{(1)}} = 0,3 - 0,01 \cdot 10,125 = 0,19875 \quad (\text{novo peso})$$

$$w_{12}^{(1)} \leftarrow w_{12}^{(1)} - \eta \cdot \frac{\partial L}{\partial w_{12}^{(1)}} = 0,4 - 0,01 \cdot 17,2125 = 0,227875 \quad (\text{novo peso})$$

$$w_{21}^{(1)} \leftarrow w_{21}^{(1)} - \eta \cdot \frac{\partial L}{\partial w_{21}^{(1)}} = 0,3 - 0,01 \cdot 16,0875 = 0,139125 \quad (\text{novo peso})$$

$$b_2^{(2)} \leftarrow b_2^{(2)} - \eta \cdot \frac{\partial L}{\partial b_2^{(2)}} = 2 - 0,01 \cdot 0,45 = 1,9955 \quad (\text{novo peso})$$

4 Framework geral da GNN

4.1 Framework

Para cada nó v_i :

Inicialização:

$$H_{v_i}^{(0)} = X_{v_i}$$

Para $k = 1, 2, \dots, \mathbb{K}$:

$$A_{v_i}^{(k)} = \text{AGG}^{(k)} \left\{ H_{v_j}^{(k-1)} : v_j \in \mathcal{N}(v_i) \right\}$$

$$H_{v_i}^{(k)} = \text{COMB}^{(k)} \left\{ H_{v_i}^{(k-1)}, A_{v_i}^{(k)} \right\}$$

Nesse caso, vamos usar

$$A_{v_i}^{(k)} = \frac{1}{|\mathcal{N}(v_i)|} \sum_{v_j \in \mathcal{N}(v_i)} H_{v_j}^{(k-1)}$$

$$\begin{aligned}
H_{v_i}^{(k)} &= \underbrace{\text{ReLU}}_{\sigma} \left(W^{(k)} \cdot \text{AGG}^{(k)} \left\{ H_{v_j}^{(k-1)} : v_j \in \mathcal{N}(v_i) \right\} + b^{(k)} \right) \\
&= \underbrace{\text{ReLU}}_{\sigma} \left(W^{(k)} \cdot \left(\frac{1}{|\mathcal{N}(v_i)|} \sum_{v_j \in \mathcal{N}(v_i)} H_{v_j}^{(k-1)} \right) + b^{(k)} \right)
\end{aligned}$$

Saída:


$$\hat{y}_{v_i} = \left(W^{(\mathbb{K})} \cdot H_{v_i}^{(\mathbb{K}-1)} + b^{(\mathbb{K})} \right)$$

4.2 Exemplo

Grafo utilizado:

Considere o grafo com $V = \{v_1, v_2, v_3, v_4\}$, onde as arestas conectam v_1-v_2 , v_2-v_3 , v_2-v_4 . As features e labels são:

$$\begin{aligned}
X_{v_i} &= [T_{v_i}, U_{v_i}], & \hat{y}_{v_i} &= P_{v_i} \\
X_{v_1} &= [30; 80], & X_{v_2} &= [35; 85], & X_{v_3} &= [26; 77], & X_{v_4} &= [25; 80]
\end{aligned}$$



Camada 1 ($k = 1$):

Parâmetros:

$$W^{(1)} = \begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} 2 \\ 1,5 \end{bmatrix}$$

Para o nó v_1 :

Vizinhança fechada: $N[v_1] = \{v_1, v_2\}$.

$$\begin{aligned}
H_{v_1}^{(0)} &= X_{v_1} = \begin{bmatrix} 30 \\ 80 \end{bmatrix} \\
A_{v_1}^{(1)} &= \frac{1}{|N[v_1]|} \left(H_{v_1}^{(0)} + H_{v_2}^{(0)} \right) = \frac{1}{2} \left(\begin{bmatrix} 30 \\ 80 \end{bmatrix} + \begin{bmatrix} 35 \\ 85 \end{bmatrix} \right) = \begin{bmatrix} 32,5 \\ 82,5 \end{bmatrix} \\
H_{v_1}^{(1)} &= \text{ReLU} \left(\begin{bmatrix} 0,5 & 0,4 \\ -0,1 & 0,2 \end{bmatrix} \begin{bmatrix} 32,5 \\ 82,5 \end{bmatrix} + \begin{bmatrix} 2 \\ 1,5 \end{bmatrix} \right) \\
&= \text{ReLU} \left(\begin{bmatrix} 0,5 \cdot 32,5 + 0,4 \cdot 82,5 + 2 \\ -0,1 \cdot 32,5 + 0,2 \cdot 82,5 + 1,5 \end{bmatrix} \right) = \begin{bmatrix} 51,25 \\ 14,75 \end{bmatrix}
\end{aligned}$$

Para o nó v_2 :

$$H_{v_2}^{(0)} = \begin{bmatrix} 35 \\ 85 \end{bmatrix}, \quad A_{v_2}^{(1)} = \begin{bmatrix} 29 \\ 80,5 \end{bmatrix}, \quad H_{v_2}^{(1)} = \begin{bmatrix} 48,7 \\ 14,7 \end{bmatrix}$$

Para o nó v_3 :

$$H_{v_3}^{(0)} = \begin{bmatrix} 26 \\ 77 \end{bmatrix}, \quad A_{v_3}^{(1)} = \begin{bmatrix} 30 \\ 82,5 \end{bmatrix}, \quad H_{v_3}^{(1)} = \begin{bmatrix} 50 \\ 15 \end{bmatrix}$$

Para o nó v_4 :

$$H_{v_4}^{(0)} = \begin{bmatrix} 25 \\ 80 \end{bmatrix}, \quad A_{v_4}^{(1)} = \begin{bmatrix} 30,5 \\ 81 \end{bmatrix}, \quad H_{v_4}^{(1)} = \begin{bmatrix} 49,65 \\ 14,65 \end{bmatrix}$$

Camada 2 ($k = 2$):

Resumo das entradas (saídas da camada 1):

$$H_{v_1}^{(1)} = \begin{bmatrix} 51,25 \\ 14,75 \end{bmatrix}, \quad H_{v_2}^{(1)} = \begin{bmatrix} 48,7 \\ 14,7 \end{bmatrix}, \quad H_{v_3}^{(1)} = \begin{bmatrix} 50 \\ 15 \end{bmatrix}, \quad H_{v_4}^{(1)} = \begin{bmatrix} 49,65 \\ 14,65 \end{bmatrix}$$

Agregações $A_{v_i}^{(2)} = \frac{1}{|N[v_i]|} \sum_{v_j \in N[v_i]} H_{v_j}^{(1)}$:

$$A_{v_1}^{(2)} = \begin{bmatrix} 49,975 \\ 14,725 \end{bmatrix}, \quad A_{v_2}^{(2)} = \begin{bmatrix} 49,85 \\ 14,85 \end{bmatrix}, \quad A_{v_3}^{(2)} = \begin{bmatrix} 49,175 \\ 14,675 \end{bmatrix}, \quad A_{v_4}^{(2)} = \begin{bmatrix} 49,9 \\ 14,775 \end{bmatrix}$$

Parâmetros:

$$W^{(2)} = \begin{bmatrix} -0,1 & 0,2 \\ 0,3 & 0,3 \end{bmatrix}, \quad b^{(2)} = \begin{bmatrix} 1,5 \\ 2,5 \end{bmatrix}$$

Como a primeira componente de $z^{(2)}$ é negativa em todos os nós, ReLU zera essa coordenada:

$$H_{v_1}^{(2)} = \begin{bmatrix} 0 \\ 21,91 \end{bmatrix} \quad (z = -0,5525), \quad H_{v_2}^{(2)} = \begin{bmatrix} 0 \\ 21,76 \end{bmatrix} \quad (z = -0,465)$$

$$H_{v_3}^{(2)} = \begin{bmatrix} 0 \\ 21,65 \end{bmatrix} \quad (z = -0,4825), \quad H_{v_4}^{(2)} = \begin{bmatrix} 0 \\ 21,90 \end{bmatrix} \quad (z = -0,535)$$

Camada de saída:

Parâmetros:

$$W_S = \begin{bmatrix} 0,7 & 0,6 \end{bmatrix}, \quad b_S = 6$$

$$\hat{y}_{v_i} = W_S H_{v_i}^{(2)} + b_S$$

Predições e rótulos:

$$\begin{aligned} \hat{y}_{v_1} &= 18,746, & y_{v_1} &= 20 \\ \hat{y}_{v_2} &= 18,73, & y_{v_2} &= 20 \\ \hat{y}_{v_3} &= 18,655, & y_{v_3} &= 22 \\ \hat{y}_{v_4} &= 18,767, & y_{v_4} &= 18 \end{aligned}$$

Função de perda:

Com n = número de nós:

$$L = \sum_{i=1}^n (y_{v_i} - \hat{y}_{v_i})^2, \quad \frac{\partial L}{\partial \hat{y}_{v_i}} = -2(y_{v_i} - \hat{y}_{v_i}) = 2(\hat{y}_{v_i} - y_{v_i})$$

$$L = (20 - 18,746)^2 + (20 - 18,73)^2 + (22 - 18,655)^2 + (18,767 - 18)^2$$

$$L = 1,5376 + 1,6129 + 11,189 + 0,588 = 14,9285$$

Objetivo: diminuir a perda através da backpropagation.

Gradientes da perda em relação às predições:

$$\frac{\partial L}{\partial \hat{y}_{v_i}} = 2(\hat{y}_{v_i} - y_{v_i})$$

$$\frac{\partial L}{\partial \hat{y}_{v_1}} = -0,62, \quad \frac{\partial L}{\partial \hat{y}_{v_2}} = -0,635$$

$$\frac{\partial L}{\partial \hat{y}_{v_3}} = -1,6725, \quad \frac{\partial L}{\partial \hat{y}_{v_4}} = 0,3835$$

Gradiente de W_S e b_S :

$$\frac{\partial L}{\partial b_S} = \sum_i \frac{\partial L}{\partial \hat{y}_{v_i}} \cdot \frac{\partial \hat{y}_{v_i}}{\partial b_S} = \sum_i \frac{\partial L}{\partial \hat{y}_{v_i}} = -2,544$$

Para $W_S = [w_{1S} \ w_{2S}]$:

$$\frac{\partial L}{\partial w_{1S}} = \sum_i \frac{\partial L}{\partial \hat{y}_{v_i}} \cdot h_{1,v_i}^{(2)}, \quad \frac{\partial L}{\partial w_{2S}} = \sum_i \frac{\partial L}{\partial \hat{y}_{v_i}} \cdot h_{2,v_i}^{(2)}$$

Como a primeira coordenada de $H_{v_i}^{(2)}$ é zero para todos os nós, $\frac{\partial L}{\partial w_{1S}} = 0$. Para a segunda:

$$\frac{\partial L}{\partial w_{2S}} = -0,62 \cdot 21,91 + (-0,635) \cdot 21,76 + (-1,6725) \cdot 21,65 + 0,3835 \cdot 21,9 = -55,2127$$

$$\frac{\partial L}{\partial W_S} = [0 \quad -55,2127]$$

Backprop. para $H^{(2)}$:

Para cada nó v_i :

$$\frac{\partial L}{\partial h_1^{(2)}(v_i)} = \frac{\partial L}{\partial \hat{y}_{v_i}} \cdot w_{1S}, \quad \frac{\partial L}{\partial h_2^{(2)}(v_i)} = \frac{\partial L}{\partial \hat{y}_{v_i}} \cdot w_{2S}$$

Para v_1 :

$$\frac{\partial L}{\partial h_1^{(2)}(v_1)} = -0,62 \cdot 0,7 = -0,434, \quad \frac{\partial L}{\partial h_2^{(2)}(v_1)} = -0,62 \cdot 0,6 = -0,372$$

$$\frac{\partial L}{\partial H_{v_1}^{(2)}} = \begin{bmatrix} -0,434 \\ -0,372 \end{bmatrix}$$

De forma análoga:

$$\frac{\partial L}{\partial H_{v_2}^{(2)}} = \begin{bmatrix} -0,4445 \\ -0,3810 \end{bmatrix}, \quad \frac{\partial L}{\partial H_{v_3}^{(2)}} = \begin{bmatrix} -1,17075 \\ -1,0035 \end{bmatrix}, \quad \frac{\partial L}{\partial H_{v_4}^{(2)}} = \begin{bmatrix} 0,26845 \\ 0,23010 \end{bmatrix}$$

Empilhando como matriz 4×2 :

$$\frac{\partial L}{\partial H^{(2)}} = \begin{bmatrix} -0,434 & -0,372 \\ -0,4445 & -0,3810 \\ -1,17075 & -1,0035 \\ 0,26845 & 0,23010 \end{bmatrix}$$

Backprop. através da ReLU para $z^{(2)}$:

$$\frac{\partial L}{\partial z_{v_i}^{(2)}} = \frac{\partial L}{\partial H_{v_i}^{(2)}} \odot \sigma'(z_{v_i}^{(2)})$$

Como todas as primeiras componentes de $z^{(2)}$ são negativas (ReLU desligada), elas zeram:

$$\frac{\partial L}{\partial z^{(2)}} = \begin{bmatrix} 0 & -0,372 \\ 0 & -0,381 \\ 0 & -1,0035 \\ 0 & 0,2301 \end{bmatrix}$$

Gradientes de $W^{(2)}$ e $b^{(2)}$:

$$\frac{\partial L}{\partial b^{(2)}} = \sum_i \frac{\partial L}{\partial z_{v_i}^{(2)}} = \begin{bmatrix} 0 \\ -0,372 \end{bmatrix} + \begin{bmatrix} 0 \\ -0,381 \end{bmatrix} + \begin{bmatrix} 0 \\ -1,0035 \end{bmatrix} + \begin{bmatrix} 0 \\ 0,2301 \end{bmatrix} = \begin{bmatrix} 0 \\ -1,4664 \end{bmatrix}$$

$$\frac{\partial L}{\partial W^{(2)}} = \left(\frac{\partial L}{\partial z^{(2)}} \right)^\top \cdot A^{(2)}$$

$$\frac{\partial L}{\partial W^{(2)}} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ -0,372 & -0,381 & -1,003 & 0,2301 \end{bmatrix} \cdot \begin{bmatrix} 49,975 & 14,725 \\ 49,85 & 14,85 \\ 49,175 & 14,675 \\ 49,9 & 14,775 \end{bmatrix}$$

$$\frac{\partial L}{\partial W^{(2)}} = \begin{bmatrix} \frac{\partial L}{\partial w_{11}^{(2)}} & \frac{\partial L}{\partial w_{12}^{(2)}} \\ \frac{\partial L}{\partial w_{21}^{(2)}} & \frac{\partial L}{\partial w_{22}^{(2)}} \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ -75,233 & -22,454 \end{bmatrix}$$

E segue para a camada 1.

Atualização dos pesos:

Para cada peso θ vale:

$$\theta \leftarrow \theta - \eta \cdot \frac{\partial L}{\partial \theta}, \quad \eta = 0,001$$

Exemplo:

$$w_{22}^{(2)} \leftarrow w_{22}^{(2)} - \eta \cdot \frac{\partial L}{\partial w_{22}^{(2)}} = 0,3 - 0,001 \cdot (-22,454) = 0,322454$$

5 Grafo k=2 e k=3

Foi utilizada a seguinte dinâmica para treino, teste e validação:

Treino	Validação	Teste
43 (70%)	6 (10%)	13 (20%)

Seguem os grafos do banco de treino, teste e validação, para $k = 2$ e $k = 3$.

Grafo k-NN das estações para $k = 2$




Figure 2: Grafo k-NN das estações meteorológicas considerando $k = 2$.

Grafo k-NN das estações para $k = 3$




Figure 3: Grafo k-NN das estações meteorológicas considerando $k = 3$.


6 Resultados obtidos

Foram feitas métricas utilizando o código acima, variando o número de neurônios da camada oculta, vizinhos que foram utilizados (quantos vizinhos mais próximos cada nó terá no grafo), e quantidade de camadas ocultas.

GNN - k = 2 - Dia 12/01/2025 (Pouca chuva)

Table 1: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.193	0.065	0.173	0.294	1.367
100	6	0.226	0.084	0.197	0.269	1.367
100	12	0.210	0.073	0.192	0.237	1.367
200	2	0.193	0.064	0.170	0.310	1.367
200	6	0.225	0.082	0.193	0.284	1.367
200	12	0.209	0.069	0.184	0.275	1.367




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 79

GNN - k = 3 - Dia 12/01/2025 (Pouca chuva)

Table 2: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.194	0.063	0.172	0.293	1.367
100	6	0.227	0.086	0.199	0.261	1.367
100	12	0.210	0.073	0.192	0.237	1.367
200	2	0.194	0.062	0.170	0.309	1.367
200	6	0.226	0.084	0.195	0.275	1.367
200	12	0.208	0.069	0.184	0.274	1.367




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 79

GNN - k = 2 - Dia 04/05/2024 (Dia das enchentes em que mais choveu)

Table 3: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	1266.293	890.724	1056.877	6.214	35.328
100	6	1374.042	1001.116	1160.110	4.031	35.328
100	12	1030.839	648.892	829.618	11.947	35.328
200	2	1097.185	716.987	893.908	10.169	35.328
200	6	1092.671	711.936	888.385	10.347	35.328
200	12	753.343	369.378	572.901	21.678	35.328




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: Não houve parada

GNN - k = 3 - Dia 04/05/2024 (Dia das enchentes em que mais choveu)

Table 4: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	1265.365	891.852	1057.963	6.166	35.328
100	6	1373.233	1001.567	1161.025	3.994	35.328
100	12	1028.699	649.052	831.481	11.846	35.328
200	2	1095.541	718.051	895.504	10.088	35.328
200	6	1090.699	712.413	890.115	10.258	35.328
200	12	749.381	367.111	574.803	21.505	35.328




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: Não houve parada

GNN - k = 2 - Dia 08/02/2025 (Zero chuva)

Table 5: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.028	0.095	0.022	0.036	0.000
100	6	0.033	0.096	0.031	0.098	0.000
100	12	0.031	0.104	0.025	0.045	0.000
200	2	0.027	0.091	0.023	0.058	0.000
200	6	0.033	0.095	0.031	0.102	0.000
200	12	0.029	0.096	0.026	0.088	0.000




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 80

GNN - k = 3 - Dia 08/02/2025 (Zero chuva)

Table 6: Resultados experimentais da GNN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.027	0.094	0.022	0.041	0.000
100	6	0.034	0.096	0.031	0.094	0.000
100	12	0.031	0.104	0.025	0.047	0.000
200	2	0.027	0.090	0.023	0.063	0.000
200	6	0.034	0.096	0.031	0.098	0.000
200	12	0.029	0.096	0.026	0.089	0.000



Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.


Última época: 80

7 Adaptação para GCN (03/06/2026)

GCN - k = 2 - Dia 12/01/2025 (Pouca chuva)

Table 7: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.196	0.063	0.172	0.320	1.367
100	6	0.224	0.091	0.200	0.225	1.367
100	12	0.209	0.073	0.191	0.228	1.367
200	2	0.195	0.062	0.169	0.335	1.367
200	6	0.223	0.089	0.197	0.240	1.367
200	12	0.208	0.070	0.184	0.263	1.367



Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.


Última época: 79

GCN - k = 3 - Dia 12/01/2025 (Pouca chuva)

Table 8: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.192	0.075	0.175	0.291	1.367
100	6	0.233	0.066	0.198	0.254	1.367
100	12	0.211	0.067	0.193	0.231	1.367
200	2	0.192	0.074	0.172	0.306	1.367
200	6	0.232	0.063	0.194	0.268	1.367
200	12	0.209	0.062	0.185	0.268	1.367

GCN - Loss de treino e teste por configuração




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 77

GCN - k = 2 - Dia 04/05/2024 (Dia das enchentes em que mais choveu)

Table 9: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	1266.730	893.875	1060.835	5.743	35.328
100	6	1374.406	1003.586	1163.335	3.668	35.328
100	12	1031.423	655.327	837.294	10.946	35.328
200	2	1097.701	722.157	900.179	9.369	35.328
200	6	1093.208	717.720	895.405	9.452	35.328
200	12	753.270	380.158	584.197	19.864	35.328




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: Não houve parada

GCN - k = 3 - Dia 04/05/2024 (Dia das enchentes em que mais choveu)

Table 10: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	1267.602	878.120	1057.056	6.153	35.328
100	6	1375.034	990.767	1160.619	3.985	35.328
100	12	1033.612	620.866	827.852	11.818	35.328
200	2	1099.457	695.343	893.049	10.064	35.328
200	6	1095.291	687.145	887.510	10.228	35.328
200	12	758.796	319.799	562.970	21.425	35.328



Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.


Última época: Não houve parada

GCN - k = 2 - Dia 08/02/2025 (Zero chuva)

Table 11: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.028	0.108	0.028	0.081	0.000
100	6	0.035	0.089	0.028	0.064	0.000
100	12	0.031	0.105	0.025	0.049	0.000
200	2	0.028	0.103	0.029	0.102	0.000
200	6	0.035	0.088	0.028	0.068	0.000
200	12	0.029	0.095	0.026	0.088	0.000

GCN - Loss de treino e teste por configuração




Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 78

GCN - k = 3 - Dia 08/02/2025 (Zero chuva)

Table 12: Resultados experimentais da GCN para diferentes configurações de hiperparâmetros.

epochs	hidden	loss_train	loss_val	loss_test	pred	true
100	2	0.027	0.101	0.025	0.041	0.000
100	6	0.036	0.094	0.028	0.090	0.000
100	12	0.031	0.105	0.025	0.044	0.000
200	2	0.026	0.096	0.026	0.064	0.000
200	6	0.036	0.093	0.029	0.094	0.000
200	12	0.029	0.096	0.026	0.086	0.000



Foi utilizado critério de parada antecipada baseado na perda de validação. O treinamento era interrompido quando a loss de validação não apresentava melhora mínima de 10^{-4} por 20 épocas consecutivas.

Última época: 79

8 Framework geral da GCN

Dado um grafo $G = (V, E, X, A)$, onde A é a matriz de adjacências e X é a matriz de features dos nós, a GCN utiliza a estrutura do grafo diretamente por meio da matriz de adjacências normalizada.

Primeiro, adicionamos auto-laços:

$$\tilde{A} = A + I$$

Em seguida, definimos a matriz de graus:

$$\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$$

A matriz de adjacências normalizada é dada por:

$$\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$

Inicialização:

$$H^{(0)} = X$$

Para cada camada $k = 0, 1, \dots, K - 1$:

$$H^{(k+1)} = \sigma \left(\hat{A} H^{(k)} W^{(k)} + b^{(k)} \right)$$

onde $W^{(k)}$ são os pesos da camada, $b^{(k)}$ é o viés e σ é uma função de ativação, como ReLU. A saída final é dada por:

$$\hat{Y} = H^{(K)} W^{(S)} + b^{(S)}$$

8.1 Exemplo

Considere o grafo com $V = \{v_1, v_2, v_3, v_4\}$, onde as arestas conectam $v_1 - v_2$, $v_2 - v_3$ e $v_2 - v_4$. As features são:

$$X_{v_1} = [30, 80], \quad X_{v_2} = [35, 85], \quad X_{v_3} = [26, 77], \quad X_{v_4} = [25, 80]$$

A matriz de adjacências é:

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

Adicionando auto-laços:

$$\tilde{A} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

A matriz de graus é:

$$\tilde{D} = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 2 \end{bmatrix}$$

Logo,

$$\hat{A} = \begin{bmatrix} 0.5 & 0.3535 & 0 & 0 \\ 0.3535 & 0.25 & 0.3535 & 0.3535 \\ 0 & 0.3535 & 0.5 & 0 \\ 0 & 0.3535 & 0 & 0.5 \end{bmatrix}$$

8.1.1 Camada 1

Tome

$$W^{(0)} = \begin{bmatrix} 0.5 & 0.4 \\ -0.1 & 0.2 \end{bmatrix}, \quad b^{(0)} = [2 \quad 1.5]$$

Primeiro calculamos:

$$\hat{A}X = \begin{bmatrix} 27.374 & 70.052 \\ 37.388 & 105.042 \\ 25.374 & 68.552 \\ 24.874 & 70.052 \end{bmatrix}$$

Então:

$$H^{(1)} = ReLU(\hat{A}XW^{(0)} + b^{(0)})$$

$$H^{(1)} = \begin{bmatrix} 8.682 & 26.460 \\ 10.190 & 37.464 \\ 7.832 & 25.360 \\ 7.432 & 25.460 \end{bmatrix}$$

8.1.2 Camada 2

Tome

$$W^{(1)} = \begin{bmatrix} -0.1 & 0.2 \\ 0.3 & 0.3 \end{bmatrix}, \quad b^{(1)} = [1.5 \quad 2.5]$$

Calculando:

$$\hat{A}H^{(1)} = \begin{bmatrix} 7.944 & 26.475 \\ 11.014 & 36.689 \\ 7.519 & 25.925 \\ 7.319 & 25.975 \end{bmatrix}$$

Logo:

$$H^{(2)} = ReLU(\hat{A}H^{(1)}W^{(1)} + b^{(1)})$$

$$H^{(2)} = \begin{bmatrix} 8.648 & 12.031 \\ 11.405 & 15.709 \\ 8.526 & 11.781 \\ 8.561 & 11.756 \end{bmatrix}$$

8.1.3 Camada de saída

Tome

$$W^{(S)} = \begin{bmatrix} 0.7 \\ 0.6 \end{bmatrix}, \quad b^{(S)} = 6$$

Então:

$$\hat{y}_{v_i} = H_{v_i}^{(2)}W^{(S)} + b^{(S)}$$

As previsões são:

$$\hat{y}_{v_1} = 19.273, \quad \hat{y}_{v_2} = 23.409, \quad \hat{y}_{v_3} = 19.037, \quad \hat{y}_{v_4} = 19.046$$